AI ДВОЙНИК НА РЪКОВОДИТЕЛЯ

Архитектурна стратегия и пътна карта

Версия: 0.6 (работна чернова)

Дата: 16.10.2026

Статус: Фаза 1.0: веригата звук → текст → подсказки работи в реална среща (облачен режим)

Роли: Собственик на продукта: Вие · Старши AI архитект и разработчик: Claude

> Това е жив документ. Обновява се след всяка фаза. Решения, отбелязани като „Предложение“, още не са одобрени.

Съдържание

1. Визия ... 3
1.1. Желани възможности (от визията) ... 3
1.2. Бизнесите на ръководителя ... 3
2. Продуктова декомпозиция ... 3
3. Взети решения ... 4
3.1. Разпределение на отговорностите ... 5
3.2. Защо TypeScript (P15) ... 6
4. Архитектура на високо ниво ... 6
4.1. Как Copilot-ът ще показва подсказки в Meet: варианти ... 7
4.2. Метод, профил и формат (P21) ... 7
5. Учене и памет ... 7
5.1. Защо има одобрение ... 7
5.2. Интервю за запознаване (предложение) ... 8
6. Необходими данни ... 8
7. Сигурност и правна рамка ... 8
8. Регистър на рисковете ... 8
9. Пътна карта (предложение) ... 9
10. План на Фаза 1.0: технически тест (одобрен) ... 10
10.1. Цел ... 10
10.2. Какво изграждаме ... 10
10.3. Кандидати за разпознаване на говор ... 10
10.4. Как измерваме ... 11
10.5. Какво е нужно от собственика ... 11
10.6. Напредък (16.10.2026) ... 11
11. Разпознаване на говор: локално или облак ... 12
11.1. Сравнение ... 12
11.2. Изисквания към компютъра за локален режим (P27) ... 13
11.3. Измерено досега ... 13
11.4. Препоръка ... 14
12. Подсказки на три нива (P30) ... 14
12.1. Какво намерихме по пътя (20.10.2026) ... 14
12.2. Безплатно или платено ... 15
13. Отворени въпроси ... 15
13.1. Очаквани материали ... 15
14. История на версиите ... 16

1. Визия

Изграждаме AI двойник (Digital Twin) на ръководител. Той познава знанията, стила и отношенията на ръководителя с хората. Може да му помага на живо в срещи и в бъдеще да го представлява по телефона и в онлайн срещи.

Проектът е **комерсиален**. Първият двойник е пилот за конкретен ръководител, а след това продуктът се предлага на външни B2B клиенти. Затова архитектурата трябва да е модулна: смяната на персоната, данните и интеграциите за нов клиент става с конфигурация, без промени в ядрото.

1.1. Желани възможности (от визията)

- Разговор по телефона от името на ръководителя, с ясно уведомяване, че е AI двойник.
- Участие в онлайн срещи (Google Meet и други платформи).
- Обучение върху знанията на ръководителя и отношенията му с хората.
- Live подсказки по време на среща, например при продажби и преговори.
- Проверка на календара на живо и предупреждение при конфликт, например при уговаряне на среща.
- Използване на инструменти и знания чрез Claude („втори мозък“).

1.2. Бизнесите на ръководителя

	Zara Computers	Zara Robotics
Какво продава	Уеб сайтове, онлайн магазини, реклама в социалните мрежи, SEO, поддръжка	Сервизни роботи Keenon (официален дистрибутор за България): почистващи, за доставка, хуманоидни, косачки
Клиенти	Малки и средни фирми, болници, частни лица	Хотели, ресторанти, здравеопазване, логистика, производство
Тип продажба	Консултативна, средна стойност	Скъпа, техническа B2B продажба. Само покупка, оглед на обекта, интеграции

> **Решение P20:** Пилотът започва със **Zara Robotics**. Сделките са скъпи и технически, затова подсказките от знанието (характеристики, съвместимост, възвращаемост) носят най-голяма стойност.

2. Продуктова декомпозиция

Визията съдържа **два различни продукта**, които делят общо ядро. Строим ги отделно, но върху едни и същи основи.

	Продукт А: Автономен двойник	Продукт Б: Live Copilot
Какво прави	Представлява шефа: говори по телефона и влиза в срещи вместо него	Помага на шефа в реално време: подсказва, проверява календара
Кой говори	AI-ят, с гласа на шефа	Шефът. AI-ят само подсказва
Човешки контрол	Няма в момента на разговора	Пълен

	Продукт А: Автономен двойник	Продукт Б: Live Copilot
Правен риск	Висок	Среден
Техническа сложност	Много висока (глас под 1 сек., телефония)	Средна

Общо ядро: персона (знания, стил, отношения), памет, интеграции (календар, CRM, имейл) и защитни механизми (guardrails).

> **Решение:** Първо се изгражда Продукт Б (Live Copilot), а след това Продукт А. Copilot-ът носи стойност веднага, рискът е нисък и всяка среща обогатява паметта, на която по-късно ще стъпи автономният двойник.

3. Взети решения

№	Решение	Статус
P1	Продуктът се разделя на Автономен двойник (А) и Live Copilot (Б) с общо ядро	Одобрено
P2	Последователност: първо Copilot, после автономен двойник	Одобрено
P3	Потребител на Copilot-а е самият ръководител	Одобрено
P4	Основна платформа за срещи: Google Meet. Задължителен слой с адаптери за Zoom, Teams и други	Одобрено
P5	Телефония (за Продукт А): мобилен номер, чрез пренасочване към облачен номер	Одобрено / техническият вариант се уточнява
P6	Подсказките се показват като текст в прозореца на самата среща	Одобрено
P7	Технология за MVP на Copilot-а: Chrome разширение с overlay върху Meet	Предложение, подкрепено от P11
P8	Ученето става чрез памет с одобрение от ръководителя, а не чрез автоматично дообучаване на модела	Предложение
P9	Правомощия на двойника по телефона (какво може да обещава и договаря)	Отложено
P10	Поддръжка и на Google Workspace, и на личен Gmail. Проектираме за общото между двете, а функциите само за Workspace са добавки	Одобрено
P11	Ръководителят участва в срещи от компютър. Това потвърждава P7 (Chrome разширение)	Одобрено
P12	Език на срещите и подсказките: български	Одобрено
P13	Ръководителят е съгласен с интервюто и с достъпа до календара и имейла. Предстои писмено съгласие	Одобрено
P14	Разработката се извършва от Claude. Собственикът осигурява акаунти, ключове и тестове в реални срещи	Одобрено

№	Решение	Статус
P15	Технологичен стек: TypeScript навсякъде (разширение + сървър) в едно монорепо	Одобрено
P16	Първа стъпка на Фаза 1: технически тест (proof of concept) на разпознаването на български говор на живо	Одобрено
P17	Бюджет засега: нула. Използваме безплатни нива, кредити за нови акаунти и локални решения. Всяка платена услуга изисква изрично одобрение	Одобрено
P18	Браузъри: всички на база Chromium (Chrome, Edge и др.) на Windows и Mac с един и същи код. Firefox и Safari по-късно, ако B2B клиенти ги поискат	Одобрено
P19	Акаунт за пилота: личен Gmail	За потвърждение
P20	Пилотът започва със Zara Robotics	Одобрено
P21	Разделяне на три слоя: Метод (пакет със знания), Профил на бизнеса, Формат на изхода. Copilot-ът зарежда профила според срещата	Предложение
P22	Данните (звук, текст, памет) се обработват и съхраняват само в ЕС от първия ден	Одобрено
P23	Планът на Фаза 1.0 (раздел 10) и целите му са одобрени	Одобрено
P24	Първият пакет със знания: публичният каталог на роботите Keenon от сайта (без лични данни)	Изпълнено (15 модела)
P25	Скиловете hormozi-coach и analyze-call (чужди) не се инсталират и не влизат в продукта. Ползват се само като образец за структура	Одобрено
P26	Разпознаване на говор само локално (на компютъра). Облачните Google и Azure са отложени	Заменено от P29
P27	Минимални изисквания към компютъра за локален режим (раздел 11)	Предложение
P28	B2B продуктът предлага два режима: локален (мощни компютри, максимална поверителност) и облачен (обикновени лаптопи)	Предложение
P29	Разпознаването на говор има два режима, избирани в настройките: на компютъра (по подразбиране) и облак, Speechmatics с регион в ЕС, за компютри без подходяща видеокарта. Облакът се включва само изрично, а участниците се уведомяват	Одобрено за пилота
P30	Подсказките са на три нива: готови фрази, разбиране по смисъл на компютъра (multilingual-e5-large) и AI отговор от фактите на фирмата (Mistral ministral-14b, сървър в ЕС, безплатен план с изключено обучение). Платен план само при нужда (раздел 12)	Одобрено (тест в Meet, 20.10.2026)

3.1. Разпределение на отговорностите

Claude	Собственик на продукта
Архитектура, код, тестове, документация	Бизнес решения и приоритети

Claude	Собственик на продукта
Подготовка на шаблони (съгласие, политики) като чернова	Правна проверка и подпис на документите
Инструкции за създаване на акаунти и настройки	Създаване на акаунтите (Anthropic, Google Cloud, хостинг) и въвеждане на ключовете лично
Автоматични тестове	Тестове в реални срещи и обратна връзка

> **Сигурност:** API ключове и пароли никога не се изпращат в чата. Въвеждат се лично от собственика в защитен конфигурационен файл, който не влиза в системата за версии.

3.2. Защо TypeScript (P15)

Chrome разширението задължително е на JavaScript/TypeScript. Ако и сървърът е на TypeScript, целият продукт е на един език: общи типове, по-малко грешки на границата между частите, по-лесна поддръжка. **Алтернатива:** сървър на Python. Той е по-силен за обработка на аудио и данни, но ще имаме два езика и две екосистеми.

4. Архитектура на високо ниво

Системата е разделена на слоеве. Всеки слой може да се сменя или разширява независимо, което е ключово за B2B модела.

Слой	Отговорност	Бележки
Канали (адаптери)	Връзка със срещи и телефон: аудио, транскрипция, участници, чат	Адаптер за Google Meet първо. Zoom, Teams и телефония по-късно. Ядрото не знае коя е платформата
Оркестрация	Решава какво да подскаже и кога. Извиква инструменти	Claude API с tool use
Персона	Стил, ценности, правила и граници на ръководителя	Конфигурация за всеки клиент, не код
Памет и знания	Краткосрочна (текущата среща) и дългосрочна (факти, решения, хора)	Записът в дългосрочна памет минава през одобрение
Интеграции (MCP)	Календар, CRM, имейл, документи	Всеки клиент получава свой набор от конектори
Защита и одит	Guardrails, защита от prompt injection, журнал на действията	Задължителен слой за всички режими
Клиенти (multi-tenant)	Изолация на данните между клиенти, роли, ключове	Проектира се от началото, дори пилотът да е един клиент

4.1. Как Copilot-ът ще показва подсказки в Meet: варианти

Вариант	Плюсове	Минуси
Chrome разширение (препоръка за MVP)	Бързо за разработка. Работи и в уеб версиите на Zoom и Teams. Има достъп до звука на таба	Само Chrome на компютър. Изисква изрично уведомяване на участниците
Официален Google Meet Add-on	Официален, видим за всички, професионален вид	Само Meet. Достъпът до аудио на живо е ограничен (предстои проверка)
Desktop приложение	Работи с всяка платформа, включително desktop Zoom	По-тежко за разработка и инсталация

4.2. Метод, профил и формат (P21)

Слой	Какво съдържа	Пример за пилота
Метод	Как се продава: типове възражения, техники, правила	Собствен пакет за B2B продажби
Профил на бизнеса	Продукти, цени, условия, граници на отстъпките, чести въпроси	Zara Robotics (после и Zara Computers)
Формат	Как се показва резултатът	Кратка подсказка на живо / отчет след срещата

Един ръководител с два бизнеса е първият реален тест на модулността. Copilot-ът определя бизнеса по събитието в календара или по имейл домейна на участниците, а ръчен превключвател служи за резервен вариант. Същият механизъм обслужва и бъдещите B2B клиенти.

> **„Вторият мозък на Claude“:** skill-овете в Claude Code работят на компютъра на разработчика, а не в продукта. В продукта същият принцип се реализира чрез Claude API + tool use + MCP сървъри.

5. Учене и памет

Моделът (Claude) не променя „мозъка“ си от разговорите. Около него изграждаме **система за памет** с два режима:

- **По време на срещата:** разбира контекста на живо (кой какво каза, какво е договорено) и подсказва на тази база.
- **След срещата:** извлича факти, решения, ангажименти и особености в стила. Ръководителят ги одобрява, преди да влязат в дългосрочната памет.

5.1. Защо има одобрение

- **Отровена памет:** един грешно запомнен факт (например размер на отстъпка) се повтаря във всяка следваща подсказка.
- **Prompt injection чрез разговора:** отсрещната страна може умишлено да каже нещо, което да манипулира AI-я.
- **GDPR:** данните на трети лица се записват съзнателно, а не безразборно.

5.2. Интервю за запознаване (предложение)

Вместо ръководителят да събира документи, AI-ят провежда 1–2 сесии, в които го разпитва за бизнеса, хората и правилата му, и структурира отговорите в база знания. Това е и **продуктова функция**: бързо включване на всеки нов B2B клиент.

6. Необходими данни

Приоритет	Данни	За какво служат
1	Продукти, ценоразпис, условия, чести възражения, граници в преговорите	Смислени подсказки в продажбите
2	Google Calendar и ключови контакти	Проверка на конфликти на живо
3	Записи и протоколи от минали срещи, имейли до клиенти	Стил и тактики на преговаряне
4	CRM история (ако има)	Контекст за всеки клиент
5	Записи на гласа (30+ мин. чисто аудио)	Само за Продукт А, по-късно

7. Сигурност и правна рамка

- **Прозрачност:** двойникът винаги казва, че е AI. Това се изисква и от EU AI Act, чл. 50. При Copilot-а се публикува автоматично съобщение в чата на срещата.
- **GDPR:** правно основание за обработка на данни на трети лица (служители, клиенти), право на изтриване, съхранение на данните в ЕС.
- **Запис на разговори:** избягваме „невидимо“ прихващане на звука без уведомяване на участниците.
- **Клониране на глас:** писмено съгласие на ръководителя и договорна рамка за употребата.
- **Изолация между клиенти:** данните на един клиент никога не са достъпни за друг.
- **Одит:** журнал на всяка подсказка и действие на системата.

8. Регистър на рисковете

Риск	Въздействие	Мярка
Двойникът поема ангажимент, който шефът не би поел	Високо	Ясни правомощия (P9), guardrails, Copilot първо
Латентност над 1 сек. при гласов разговор	Високо (за А)	Тестове на веригата говор → модел → глас преди обвързване
Слабо качество на говора на български	Средно	Сравнителни тестове на доставчици за разпознаване и синтез
Отровена памет	Високо	Одобрение преди запис в дългосрочната памет
Prompt injection от участник в срещата	Високо	Разделяне на инструкции и съдържание, guardrails, тестове
Нарушение на GDPR при запис	Високо	Уведомяване, съхранение в ЕС, политика за изтриване

Риск	Въздействие	Мярка
Зависимост от API-тата на Google Meet	Средно	Слой с адаптери, резервен вариант с Chrome разширение
Проверка на приложението от Google (OAuth verification) за достъп до Calendar и Gmail при външни клиенти	Високо (за B2B)	За пилота: тестов режим без проверка. Преди продажба: планиране на време и бюджет за проверката. Достъпът до Gmail може да изисква и независим одит на сигурността
Качество и скорост на разпознаване на български говор на живо	Високо	Технически тест (P16) с реални записи, преди да изберем доставчик
Безплатните нива имат лимити, а някои безплатни услуги използват данните за обучение на моделите си	Високо	Ползваме само услуги, чиито условия забраняват обучение върху нашите данни. За поверителни срещи: локално решение или платено ниво
Claude API не е безплатен	Средно	Във Фаза 1.0 не е нужен. Решение за малък бюджет преди Фаза 1 (MVP)
Неизвестно е каква част от продажбите на роботи са онлайн и каква на живо (огледи на обекти)	Средно	Измерване по време на пилота. По-късно: режим за срещи на живо през телефона
В срещите вероятно присъства и ботът на Fathom	Ниско	Тест за съвместна работа. Транскриптите на Fathom служат за сравнение на точността
Права върху чужди скилове и съдържание (Мартин, Hormozi)	Средно	Не се вграждат в продукта (P25). Съдържанието е собствено
В облачния режим звукът от срещата напуска компютъра	Високо	Само при изричен избор (P29), регион в ЕС, уведомяване на участниците. Преди клиенти: договор за обработка на данни (DPA) с доставчика и проверка, че не обучава модели върху нашите данни
Безплатният облак има лимит 2 едновременни връзки, а условията му може да се сменят	Средно	Една среща ползва точно 2. Изключване на Copilot, когато не се ползва. Ясно съобщение при зает облак. Преди клиенти: платен план или друг доставчик зад същия интерфейс
API ключът за облака стои в разширението	Средно	Приемливо за пилота на един компютър. За клиенти: временни ключове от наш сървър
Без слушалки гласът на клиента влиза и в микрофона	Средно	Филтър за ехо в панела. Препоръка за слушалки в инструкцията

9. Пътна карта (предложение)

Фаза	Цел	Резултат
0. Визия и обхват	Изясняване на целта, решенията и рисковете	Този документ, одобрен

Фаза	Цел	Резултат
1.0. Технически тест	Звук от Meet → разпознаване на български → текст в прозореца на срещата. Без AI подсказки	Измерени качество и закъснение. Избран доставчик
1. Live Copilot MVP	Подсказки и проверка на календара в Google Meet	Работещ пилот за ръководителя
2. Памет и интервю	Дългосрочна памет с одобрение, интервю за запознаване	Персона и база знания
3. Автономен двойник: текст	Тесен обхват: насрочване на срещи, отговори на чести въпроси	Пилот с ясни правомощия
4. Автономен двойник: глас	Телефон и срещи с гласа на ръководителя	Гласов двойник
5. B2B продукт	Multi-tenant, шаблони, бързо включване на клиенти	Комерсиален продукт

10. План на Фаза 1.0: технически тест (одобрен)

10.1. Цел

Да докажем, че можем да превърнем разговор в Google Meet в български текст **достатъчно точно и достатъчно бързо**, и то без разходи. AI подсказки в тази фаза няма.

10.2. Какво изграждаме

- Минимално Chrome разширение, което взима **два отделни звука**: звука от таба на Meet (другите участници) и микрофона (ръководителя). Така безплатно знаем кой говори: ръководителят или отсрещната страна.
- Изпращане на звука към избрания доставчик за разпознаване и показване на текста в панел върху прозореца на Meet.
- Измерване на закъснението и запис на резултатите за сравнение.
- Видимо уведомяване, че срещата се транскрибира.

10.3. Кандидати за разпознаване на говор

Кандидат	Цена	Плюсове	Минуси
Google Cloud Speech-to-Text	Безплатно ниво (минути на месец)	Поддържа български, работи на живо, има региони в ЕС	Лимитът на безплатното ниво е малък
Microsoft Azure Speech	Безплатно ниво (часове на месец)	Поддържа български, работи на живо, има региони в ЕС	Изисква акаунт в Azure
Whisper локално (на компютъра)	Безплатно	Пълна поверителност, без лимити	Качеството и скоростта зависят от компютъра. Не е истински поток на живо

Кандидат	Цена	Плюсове	Минуси
Speechmatics (избран за облака, P29)	Безплатен акаунт без банкова карта	Български, поток на живо, регион в ЕС, речник с имената на продуктите	Лимит 2 едновременни връзки. Безплатните условия може да се сменят

Регистрацията в Azure не мина: искаше абонамент и банкова карта. Speechmatics не изисква карта, затова е избран за сравнението и за облачния режим.

> Точните лимити и условия на безплатните нива ще проверим към момента на регистрацията. Те се променят.

10.4. Как измерваме

Показател	Как	Цел (предложение)
Точност	Процент грешни думи спрямо ръчно поправен текст на 10 мин. реален разговор	Под 15% грешни думи
Закъснение	Време от изговаряне до появата на текста	Под 2 секунди
Цена	Разход при 10 часа срещи месечно	0 лв. във Фаза 1.0
Поверителност	Условия на доставчика: обучават ли се върху данните, къде се съхраняват	Без обучение, ЕС

10.5. Какво е нужно от собственика

- 1–2 записа на реални разговори на Zara Robotics (вероятно от Fathom), със съгласието на участниците, заедно с транскрипта на Fathom за сравнение.
- Създаване на безплатни акаунти при избраните доставчици по мои инструкции.
- Тест на разширението в 2–3 реални срещи и кратка обратна връзка.

10.6. Напредък (16.10.2026)

Стъпка	Състояние
Основа на проекта: монорепо, ядро, git, частно GitHub хранилище	Готово
Chrome разширение: панел в Meet, прихващане на звука (таб и микрофон поотделно)	Готово, проверено в реална среща
Локален Whisper и инструмент за измерване	Готово. На слаб лаптоп не постига целите (раздел 11)
Облачно разпознаване (Speechmatics, ЕС) като избор в настройките	Готово, проверено в реална среща: около 2 s след изречението
Пакет със знания Zara Robotics и разпознаване на модели в разговора	Готово (15 модела, без цени). Подсказки за продукт, възражение и липсваща цена излизат в срещата

Стъпка	Състояние
Измерване на компютъра на ръководителя (Mac) и с реален запис	Чака достъп до компютъра и записа

Поправени пречки по пътя (16.10.2026):

- Chrome отказваше прихващането на таба, докато разширението беше с изолация COOP/COEP. Изолацията е махната. Цената е една нишка за разпознаването на процесора, което почти не забавя (около 8%).
- Звукът спираше след първите 100 ms заради грешка при рязането на парчета. Затова в ранните тестове нямаше текст нито локално, нито в облака. Поправено и покрито с тест.
- На вградена видеокарта AMD Vega големият модел зависва. Разширението вече го проверява с истински говор и при нужда минава на процесора.
- Тих микрофон (около -46 dBFS): автоматично усилване преди облака.
- Без слушалки едно изречение идваше два пъти (от микрофона и от таба): филтър за ехо.
- Бутон „Логове“ в панела: диагностика без DevTools.

11. Разпознаване на говор: локално или облак

Въпросът е **кой „слуша“ разговора и превръща говора в текст**: самият компютър (локално) или сървър в ЕС (облак). От 16.10.2026 решението е P29: и двата режима, избирани в настройките. По подразбиране се ползва локалният.

11.1. Сравнение

	Локално	Облак (регион в ЕС)
Къде отива звукът	Никъде, остава на компютъра	В сървър на доставчика в ЕС
Скорост	Зависи от компютъра	Бърза на всеки компютър
Точност на български	Зависи от модела, който компютърът може да изпълни	По-висока
Цена	0	Безплатно до лимит, после на минута. Двата потока (ръководител и клиент) се броят поотделно, през цялото време на включен Copilot
Подготовка	Нищо (моделът се сваля веднъж)	Акаунт и ключ (Speechmatics: без карта). За клиенти: сървър, който издава временни ключове
Работа без интернет	Да	Не
Аргумент пред B2B клиенти	„Звукът никога не напуска компютъра ви“	„Работи на всеки лаптоп“
Основен риск	Слаб компютър: закъснение и грешки	Зависимост от външна фирма

11.2. Изисквания към компютъра за локален режим (P27)

Ниво	Компютър	Очакване
✅ Препоръчително	Видеокарта NVIDIA RTX 3060 / 4060 или по-нова, с поне 8 GB видео памет. 16 GB RAM или повече. 8-ядрен процесор	Най-добрият модел (large-v3-turbo), текст за около 1–2 s
✅ Mac	Apple M1 Pro / M2 / M3 или по-нов, 16 GB RAM	Вероятно като горното
⚠ На границата	Без отделна видеокарта, нов 8-ядрен процесор (Ryzen 7 серия 7000/8000, Intel Core Ultra 7), 16 GB RAM	По-лек модел, по-ниска точност. Нужен тест
❌ Не става	2–4 ядра, 8 GB RAM, по-стар или офис лаптоп	Закъснение 10–20 s, твърде много грешки

Таблицата е **оценка по общи данни, не измерване**. Окончателен отговор дава tools/hardware-check.ps1 и тест на конкретния компютър. За всички нива: Windows 10/11 (64-битов) или macOS, около 2 GB свободно място, лаптопът в контакта по време на срещата.

11.3. Измерено досега

Слаб лаптоп (AMD Ryzen 3 3250U, 2 ядра, 10 GB RAM, вградена AMD Vega), чист синтетичен глас на български. Цел: под 15% грешни думи и под 2 s закъснение.

15.10.2026, Node (извън браузъра), 56 s запис:

Модел	Грешни думи	Скорост спрямо говора	Закъснение
whisper-base	57,6%	1,1× по-бавен	7–8 s
whisper-small	28,8%	3× по-бавен	15–20 s

16.10.2026, в браузъра, както работи разширението, 16 s запис, нарязан на изречения:

Вариант	Грешни думи	Скорост спрямо говора	На изречение от 4,3 s
whisper-base, процесор	67,6%	1,5× по-бавен	7,5 s
whisper-small, процесор (1 нишка)	20,6%	4,8× по-бавен	23,9 s
whisper-small, процесор (4 нишки)	не е мерено	почти същото	20,5 s
large-v3-turbo, видеокарта AMD Vega	не е мерено	зависва	над 2 мин без резултат
Speechmatics на живо (облак, ЕС)	2,9%	в реално време	0,9–2,2 s

16.10.2026, реална среща в Google Meet (облак): текст от двете страни около 2,0–2,1 s след изречението. В срещата излязоха подсказките за продукт (Dinerbot T8), за възражение „цена“, за липсваща цена и за дела на говорене.

Извод: на компютър без подходяща видеокарта локалното разпознаване на живо не е възможно с никой от моделите. По-малкият модел е 3 пъти по-бърз, но греши 2 от 3 думи. Облакът стига целите на всеки компютър. На мощен компютър с NVIDIA (15.10) large-v3-turbo даде 5,9% грешни думи.

11.4. Препоръка

- **Пилот (P29):** тестът на компютъра решава. Ако компютърът е от първите две нива, ползва се локалният режим. Иначе облакът (Speechmatics, ЕС), с уведомяване на участниците.
- **B2B продукт (P28):** два режима по избор на клиента. Възможен е и смесен вариант: облак на живо, локален модел за пълния транскрипт след срещата.
- **Точността в истински разговор** (шум, прекъсвания, двама говорещи) не е измерена. Нужен е реален запис.

12. Подсказки на три нива (P30)

Copilot търси отговор на всяко изречение на клиента на три нива, от най-бързото към най-умното. Първото, което даде карта, печели.

Ниво	Модел	Къде работи	Цена	Какво може
1. Готови фрази	Без модел: думите от пакета	В панела	0	Мигновено, за най-честите въпроси и възражения. Само записаните думи
2. По смисъл	multilingual-e5-large (Microsoft, отворен код, 540 MB)	На компютъра	0	Въпрос с други думи → най-близката готова тема. Не съчинява текст
3. AI отговор	ministral-14b-2512 (Mistral AI, Франция)	Сървърът на Mistral в ЕС, през функцията suggest в Supabase	0 (безплатен план)	Чете разговора и съставя 1–2 изречения само от фактите на фирмата, с етикет „AI“

Преди трите нива гласът става текст: Speechmatics (облак, ЕС) или Whisper на компютъра (P29).

12.1. Какво намерихме по пътя (20.10.2026)

- Само по смисъл, без AI, в реалните разговори даваше предимно грешни карти. Сега отговаря по смисъл само на въпроси, а възражения показва само при много висок отстъп.
- Малък езиков модел на компютъра (Qwen 2.5, 1,5 млрд.): 95–120 s на отговор и развален български. Не става.
- Безплатните облаци извън ЕС (Gemini и др.) ползват данните за обучение и не са в ЕС: против P22.
- Mistral: безплатен план, обучението върху нашите заявки е изключено от собственика. Моделът mistral-small даваше „429 Rate limit“ (20 000 токена/мин); ministral-14b има 937 500 токена/мин и работи.

12.2. Безплатно или платено

	Безплатен план (cera)	Платен план на Mistral
Лимит	Около 1 заявка на 2 s, общ за всички колеги	Много по-висок: няколко колеги в срещи едновременно
Модел	ministral-14b (добър, среден по размер)	И по-големите (mistral-medium, mistral-large): по-добър български и по-точни отговори на трудни въпроси
Данни	Обучението е изключено с превключвател	Изключено по подразбиране по договор (за B2B клиенти)
Цена	0	По ценоразписа на Mistral, при пилота очаквано няколко евро на месец. Изисква одобрение (P17)

> **По-голямото подобрение не идва от модела:** AI е толкова точен, колкото е текстът на разговора (чист звук, слушалки) и фактите в пакета. Без политика за отстъпки и срок за доставка той отговаря „ще ви го уточня в офертата“.

13. Отворени въпроси

1. Компютърът на ръководителя (Mac): модел, резултат от теста на компютъра в разширението и тест в реална среща.
2. Потвърждение на P19: личният Gmail ли ще ползва ръководителят?
3. Fathom ли ползва ръководителят и с какъв план (безплатен или платен)?
4. Каква част от продажбите на роботи са онлайн срещи и каква на живо?
5. Одобрение на P21 (метод, профил, формат), P27 (изисквания към компютъра) и P28 (два режима за B2B).
6. Облакът в срещи с истински клиенти (P29): текст за уведомяване на участниците и договор за обработка на данни с доставчика.
7. Клиентските отзиви от сайта (Kaufland, Technopolis и др.): реални ли са и може ли да се споменават в разговори?
8. Платен план на Mistral (раздел 12.2): кога, ако колегите са в срещи едновременно или трябва по-добър модел.
9. Малък бюджет за Claude API преди Фаза 1 (MVP), когато стигнем дотам.
10. Правомощия на двойника по телефона (P9).

13.1. Очаквани материали

- **Zara Robotics:** ценоразпис, граници на отстъпките, чести въпроси и възражения на клиенти, техническа документация от Keenon. Собственикът ще ги изпрати (напомняне при старта на работата по пакета със знания).
- **Записи за теста:** 1–2 разговора от Fathom с транскриптите им.

14. История на версиите

Версия	Дата	Промени
0.1	15.10.2026	Първа чернова: визия, декомпозиция, решения P1–P9, архитектура, рискове, пътна карта
0.2	15.10.2026	Решения P10–P16, разпределение на отговорностите, нови рискове (проверка от Google, български говор), технически тест 1.0, нови отворени въпроси
0.3	15.10.2026	Одобрени P15 и P16. Решения P17–P19 (нулев бюджет, браузъри, Gmail). План на Фаза 1.0. Рискове на безплатните услуги
0.4	15.10.2026	Бизнесите на ръководителя. Решения P20–P25 (пилот със Zara Robotics, метод/профил/формат, данни само в ЕС, одобрен план на Фаза 1.0). Нови рискове. Очаквани материали
0.5	15.10.2026	Напредък на Фаза 1.0. Решения P26–P28 (само локално разпознаване, изисквания към компютъра, два режима за B2B). Сравнение локално/облак и първи измервания (раздел 11)
0.6	16.10.2026	Решение P29 (два режима на разпознаване: на компютъра и облак Speechmatics в ЕС), P26 е заменено. Първата работеща верига в реална среща. Измервания в браузъра и в облака. Поправени пречки. Нови рискове на облачния режим
0.7	20.10.2026	Решение P30: подсказки на три нива (фрази, смисъл на компютъра, AI отговор от Mistral в ЕС). Нов раздел 12 с намереното и сравнение безплатно/платено